

OpenData Copilot

Reporte final — Pregúntale a los datos abiertos de Colombia

Concurso	Datos al Ecosistema 2026 — MinTIC
Proyecto	ID 241 · Nivel Avanzado
Equipo	Yehison Fabian Becerra · Edwin Giovanni Villamizar Aldana · Yenny Alarcon · Helen Daniela Benitez Hipolito
Repositorio	github.com/jasonfabian8/JYDE.OpenDataCopilot (MIT)
Fecha de generación	11/07/2026
Generado por	reports/generar_reporte.py sobre el sistema en ejecución

1. Resumen ejecutivo

Colombia publica más de 8.000 conjuntos de datos abiertos en datos.gov.co, pero siguen siendo inaccesibles para la mayoría de los ciudadanos: encontrarlos y usarlos exige conocer portales, formatos técnicos y lenguajes de consulta. **OpenData Copilot** elimina esa barrera: el ciudadano pregunta en lenguaje natural y un sistema multiagente de IA descubre los datasets relevantes, consulta los datos en vivo y responde **citando siempre la fuente oficial**.


El prototipo está operativo de extremo a extremo: catálogo real ingerido vía la API de Socrata, búsqueda semántica (RAG) sobre MongoDB Atlas Vector Search, 6 agentes especializados orquestados con GPT-4.1-mini (Azure AI Foundry), streaming SSE, auditoría integral y 270 pruebas automatizadas con una cobertura exigida $\geq 95\%$ por proyecto.

Hallazgos principales

- El catálogo público contiene **11,685 datasets** en 29 categorías; la ingesta de una categoría completa toma segundos.
- La búsqueda híbrida (embeddings + keyword) recupera candidatos pertinentes y el LLM recalcula su relevancia: sólo se citan las fuentes que superan el umbral (50%).
- El guardrail anti-alucinación funciona en la práctica: cuando los datos sólo se relacionan parcialmente con la pregunta, el sistema lo declara en la respuesta.
- El agente de cifras genera SoQL y lo ejecuta en vivo sobre la API de datos.gov.co, devolviendo tablas verificables en lugar de números inventados.
- Toda interacción de todo agente queda registrada en la auditoría (gobierno de IA).

2. Uso de datos abiertos


La única fuente de datos es la API oficial de Socrata de datos.gov.co (catálogo + SoQL), sin web scraping (ADR-0002). El estado del catálogo al generar este reporte:




Datasets en el portal	11,685
Categorías temáticas	29
Datasets en el índice local	8,407
Estrategia	Híbrida (ADR-0005): metadatos amplios + consulta de datos en vivo

3. Inteligencia artificial: sistema multiagente con RAG

La conversación la resuelve un equipo de 6 agentes especializados (enrutador, objetivo, categorías, recomendador, analista y cifras) coordinados por el Copilot Orquestador (ADR-0015). El RAG recupera del índice vectorial los datasets candidatos y el LLM razona únicamente sobre ese contexto: sin fuente no hay respuesta.



Distribución real de interacciones registradas por la auditoría durante las preguntas de evidencia de este reporte.



4. Resultados, métricas y evidencias

Preguntas de evidencia ejecutadas contra el sistema real

P1. ¿Qué datasets hay sobre accidentalidad vial?

Agente: [dataset-recommender-agent](#) · Fuentes citadas: —

«Ninguno de los datasets listados trata directamente sobre accidentalidad vial. Sin embargo, el dataset 'Mantenimiento Vial Palmira 2008-2019' puede tener una relación muy indirecta con el tema ya que aborda aspectos de infraestructura vial, pero no cubre datos específicos de accidentes viales.»

P2. ¿Qué datasets me recomiendas sobre salud en los municipios de Colombia?

Agente: [dataset-recommender-agent](#) · Fuentes citadas:

Encuesta_Salud_Derechos_Sexuales-Y-Reproductivos


«Para su consulta sobre salud en los municipios de Colombia, le recomiendo el dataset 'Encuesta_Salud_Derechos_Sexuales-Y-Reproductivos' porque está relacionado directamente con temas de salud y aborda aspectos relevantes como derechos sexuales y reproductivos, que pueden incluir información desagregada por municipios. Los demás datasets no están relacionados con salud o municipios.»

P3. ¿Cuántos registros tiene el dataset de mantenimiento vial de Palmira?


Agente: [figures-agent](#) · Fuentes citadas: [Infracciones viales Palmira](#)

«El dataset 'Infracciones viales Palmira' está relacionado con datos viales en Palmira. Para conocer la cantidad total de registros presentes en este dataset, se cuenta el total de filas sin filtros.»

Dato en vivo (SoQL): [Infracciones viales Palmira](#) — total_registros: 177




Métricas de ingeniería (extraídas del repositorio al generar el reporte)




5. Evidencia visual del prototipo

Capturas de la demo automatizada (demo/record-demo.js, Playwright sobre el sistema real; video completo en demo/OpenDataCopilot_Demo_ID241.mp4).



Respuesta del Copilot con fuentes citadas, relevancia y enlace oficial.



Cifra calculada con SoQL en vivo; la tabla llega al panel de artefactos.

OpenData Copilot

Nuevo chat

CHATS

¿Qué datasets hay sobre a...

Configuraciones

Volver al inicio

Datos de datos.gov.co - siempre citados

OPENDATA COPILOT

VIA DATASET-RECOMMENDER-AGENT

Memoria

Artefactos

Auditoría

FUENTES CITADAS

Mantenimiento Vial Palmira 2008-2019 50%

El dataset 'Mantenimiento Vial Palmira 2008-2019' puede ser parcialmente relevante para la consulta de accidentalidad vial, ya que aunque se enfoca en mantenimiento vial, este tema está vinculado indirectamente a la accidentalidad. Sin embargo, ninguno de los datasets listados aborda directamente la accidentalidad vial. Se recomienda reformular la consulta con términos relacionados como 'accidentes de tránsito', 'sinistralidad vial', especificar municipio o periodo, o solicitar la búsqueda en categorías específicas de transporte o seguridad vial para obtener mejores resultados.

¿Cuántos registros tiene el dataset de mantenimiento vial de Palmira?

VIA FIGURES-AGENT

FUENTES CITADAS

Registros de activos de información 2021 100%

Figur

Consulta para obtener el total de registros en el dataset 'Mantenimiento Vial Palmira 2008-2019'.

¿Y qué datasets me recomiendas sobre seguridad vial en los municipios del Valle del Cauca?

VIA DATASET-RECOMMENDER-AGENT

FUENTES CITADAS

Consolidado de Personas Socializadas y Sensibilizadas en el Departamento del Valle del Cauca 50%

Figur

Ninguno de los datasets listados trata específicamente sobre seguridad vial en los municipios del Valle del Cauca. Sin embargo, el dataset 'Consolidado de Personas Socializadas y Sensibilizadas en el Departamento del Valle del Cauca' (categoría Transporte) podría tener alguna relación indirecta si aborda campañas o actividades de prevención vial. Para obtener datos específicos sobre seguridad vial, accidentes de tránsito, o sinistralidad vial en el Valle del Cauca, se recomienda buscar en categorías de transporte, seguridad, movilidad o consultar directamente bases específicas de tránsito y control vial. ¿Desea que revise otras categorías o fuentes para ayudarle mejor?

Escribe tu pregunta...

Auditoría

USUARIO

¿Y qué datasets me recomiendas sobre seguridad vial en los municipios del Valle del Cauca?

ROUTER-AGENT

DATASET-RECOMMENDER-AGENT

OBJECTIVE-TRACKER-AGENT

USUARIO

¿Cuántos registros tiene el dataset de mantenimiento vial de Palmira?

ROUTER-AGENT

FIGURES-AGENT

OBJECTIVE-TRACKER-AGENT

USUARIO

¿Qué datasets hay sobre accidentalidad vial?

ROUTER-AGENT

DATASET-RECOMMENDER-AGENT

OBJECTIVE-TRACKER-AGENT

Panel de auditoría: cada interacción de cada agente queda registrada.

6. Conclusiones

- Los datos abiertos generan valor cuando cualquier persona puede usarlos: el prototipo demuestra que una pregunta en lenguaje natural basta para llegar al dato oficial citado.
- La arquitectura multiagente + RAG produce respuestas confiables y auditables, no un chatbot genérico: cada afirmación es trazable hasta su dataset de origen.
- La arquitectura hexagonal con puertos y adaptadores (ADR-0003) permitió construir con costo cercano a cero y desplegar con proveedores gestionados sin tocar el núcleo.
- La disciplina de ingeniería (270 tests, cobertura $\geq 95\%$, 16 ADRs, SonarCloud y SAST en CI) hace del prototipo una base lista para producción, no un experimento.