

OpenData Copilot

Pregúntale a los datos abiertos de Colombia

“Los datos abiertos solo generan valor cuando las personas pueden entenderlos y utilizarlos.”



> ¿Qué municipios tienen mayor desempleo?

⚙ consulta SoQL sobre datos.gov.co...

Los 5 municipios con mayor índice son...

📄 Fuente: **DANE** — datos.gov.co

EQUIPO

Y

Yehison Fabian Becerra

EEdwin Giovanni
Villamizar Aldana**Y**

Yenny Alarcon

HHelen Daniela Benitez
Hipolito

Asistente de IA conversacional sobre los 8.000+ datasets de datos.gov.co — cada respuesta cita su fuente.

Miles de datos públicos que casi nadie puede usar



8.000+ datasets publicados

datos.gov.co concentra salud, educación, seguridad, economía y ambiente.



Barrera técnica real

Encontrar el dataset correcto exige conocer portales, CSV, APIs y SoQL.



Valor público dormido

La información existe, pero no llega a quien decide ni a quien pregunta.

¿A QUIÉNES AFECTA Y POR QUÉ?

Ciudadanos

Deciden a diario sin poder verificar la información pública.

Periodistas

Verificar una cifra les toma días entre portales y CSV.

Investigadores

Gastan el tiempo buscando y limpiando datos, no analizándolos.

Emprendedores

Sin datos usables no detectan oportunidades ni mercados.

Entidades

Publican datos que nadie usa: transparencia sin retorno.




OBJETIVO

Que cualquier persona consulte los datos abiertos con una pregunta en lenguaje natural y reciba una respuesta clara, verificable y siempre citando su fuente.

datos.gov.co como única fuente, vía API oficial

FLUJO DE DATOS



Solo API oficial

Cero web scraping (ADR-0002): datos trazables y términos de uso respetados.



Estrategia híbrida

Metadatos amplios de todo el catálogo + cache selectivo de los datasets más usados.



Calidad y trazabilidad

Cada respuesta enlaza al dataset original; sin fuente no hay respuesta.

Los datos nunca se copian a ciegas: se consultan en vivo con SoQL sobre la fuente oficial y se citan en la respuesta.

Copilot multiagente con RAG y respuestas citadas

ARQUITECTURA DE INFERENCIA



Un buscador tradicional entrega archivos. **OpenData Copilot** entrega respuestas con evidencia.

Seis agentes de IA que colaboran, no un chatbot

1 · PREGUNTA

 **Ciudadano**
pregunta en lenguaje natural

 **Agente de objetivo**
memoria: resume el propósito y acompaña cada turno

Entrega: la pregunta + el objetivo acumulado.

2 · ORQUESTACIÓN

 **Copilot Orquestador**
agente enrutador: clasifica la intención y delega en el experto

 **Categorías** · qué cargar del catálogo

 **Recomendador** · qué datasets responden

 **Analista** · columnas y cruces

 **Cifras** · números reales vía SoQL

Entrega: la tarea al agente experto.

3 · CONTEXTO (RAG)

Embedding de la pregunta
vector semántico

Índice vectorial
metadatos de 8.000+ datasets

Top-k datasets relevantes
el contexto que recibe la IA

 **datos.gov.co en vivo (SoQL)**

Entrega: pregunta + datasets como contexto.

4 · RESPUESTA

 **GPT-4.1-mini**
razona con pregunta + contexto (Azure AI Foundry)

 **Respuesta citada**
fuentes + tablas + gráficas streaming SSE

 **Sin fuente no hay respuesta**

6 agentes · enrutador, objetivo, categorías, recomendador, analista y cifras — recuperan (RAG), razonan (IA) y responden con evidencia.


IA segura, observable, versionada y lista para producción



FEEDBACK LOOP — EL SISTEMA APRENDE CON EL USO



El prototipo ya funciona: esto es lo que validamos



► **DEMO EN VIVO:** pregunta → consulta SoQL → respuesta con fuente citada

VALIDACIONES COMPLETADAS



Ingesta real del catálogo

metadatos leídos desde la API Socrata de datos.gov.co



Búsqueda semántica operativa

embeddings + índice híbrido en Atlas Vector Search



El chat responde citando la fuente

multiagente + streaming SSE de extremo a extremo



Calidad verificada en CI

build y umbral de cobertura bloquean cualquier regresión

121 tests

≥95% cobertura

16 ADRs

4 bounded contexts

Bajo costo capas gratuitas y modelos económicos

Del dato abierto a la decisión informada



Ciudadanía
50M+ colombianos pueden preguntar sin saber de datos.



Periodismo e investigación
Evidencia verificable y citada en segundos.



Entidades públicas
Sus datos por fin se usan: transparencia con retorno.



Territorio
32 departamentos y 1.100+ municipios con datos consultables.

DECISIONES QUE HABILITA

 Salud

 Educación

 Seguridad

 Presupuesto

 Ambiente

 Conectividad




Escalabilidad
Backend stateless + servicios gestionados de Azure.
Nueva capacidad = nuevo agente, sin reescribir el núcleo.



Sostenibilidad
Bajo costo: modelos económicos y capas gratuitas.
Proveedores intercambiables por configuración: sin lock-in.

Ingeniería sólida detrás de una idea simple



Dependencias sólo hacia adentro: Api → Infrastructure → Application → Domain

FRONTEND

React + Vite
Zustand
Tailwind CSS
Vitest

BACKEND

.NET 10
ASP.NET Core
xUnit + Shouldly
Hexagonal + DDD

INFRAESTRUCTURA

MongoDB Atlas
Atlas Vector Search
Azure AI Foundry
Docker



Libertad tecnológica

Cambiar de LLM, base de datos o índice no toca el núcleo: es un cambio de configuración.



Calidad de nivel industrial

TDD, cobertura $\geq 95\%$ y CI que bloquea regresiones: el prototipo no es un experimento frágil.



Abierto y verificable

Código MIT en GitHub con toda la arquitectura documentada: cualquiera puede auditarlo hoy.



Calidad de código con SonarCloud


análisis continuo en cada cambio: bugs, vulnerabilidades, code smells y deuda técnica

github.com/jasonfabian8/JYDE.OpenDataCopilot · MIT

De asistente inteligente a plataforma autoevolutiva



CICLO AUTOEVOLUTIVO



Visión: una plataforma agéntica autoevolutiva, gobernada por IA, que aprende del uso, optimiza su desempeño y escala de forma segura para un mayor impacto nacional.

POR QUÉ ESTE PROYECTO

De 8.000 datasets a una sola pregunta.



Innovación

Multiagente + RAG citado: no un chatbot, un copiloto con evidencia.



IA responsable

Guardrails explícitos: sin fuente no hay respuesta, nunca inventa cifras.



Datos abiertos de verdad

100% sobre la API oficial de datos.gov.co, trazable y reproducible.



Escalable y sostenible

Hexagonal, stateless y de bajo costo: lista para nivel nacional.

Los datos abiertos ya existen. Nosotros los hacemos hablar.

OpenData Copilot convierte la transparencia en conversación: información pública, comprensible y verificable para cada colombiano.



Escanea el repositorio
github.com/jasonfabian8

ID 241

NIVEL AVANZADO

DATOS AL ECOSISTEMA 2026

¡Gracias!